

GLM-5.2、Kimi K3、 DeepSeek V4 后训练路线图

Training Report 对照研究、逐节点数据审计、
12-16 周工程 Roadmap 与 4 周教学 Walk-through

研究时点：2026-08-03 | 版本：1.0 | 中文

[D] 官方直接披露

[C] 透明算术推导

[R] 工程建议

核心问题：三家如何设计后训练 pipeline？各 node 使用什么数据、奖励和 rollout 系统？哪些规模已公开，哪些仍然未知？

目录

本报告按“证据边界 → 单模型 pipeline → 横向比较 → 数据审计 → Roadmap → 教学计划”组织。

Executive Summary	5
先给结论	5
一页比较	5
第一部分 证据边界与阅读方法	6
1.1 三个 “report” 并不对称	6
1.2 什么才叫 “RL 做了多少数据”	6
1.3 证据等级	6
第二部分 三条后训练 Pipeline	7
2.1 GLM：从串行塑形到长程 single-rollout RL	7
2.1.1 GLM-5 报告中的完整基础流水线 [D]	7
2.1.2 GLM-5.2 的增量 [D]	7
2.1.3 GLM 的核心设计逻辑	8
2.2 Kimi K3：3 域 × 3 effort 的 9 专家系统	8
2.2.1 总流水线 [D]	8
2.2.2 节点拆解 [D]	9
2.2.3 为什么 partial rollout 很关键	9
2.2.4 Kimi 的训练对象已经是 “环境包”	9
2.3 DeepSeek V4：Specialist GRPO 与完整词表 OPD	10
2.3.1 总流水线 [D]	10
2.3.2 节点拆解 [D]	10
2.3.3 Full-vocabulary OPD 为什么不同	10
2.3.4 WAL 解决的不只是可靠性	11
第三部分 横向比较：相同目标，不同技术选择	12
3.1 Pipeline 拓扑	12
3.2 RL 算法选择	12

3.3 Reward 设计	12
3.4 OPD 的三种实现	13
3.5 长上下文的三种“状态观”	13
第四部分 数据比例与 RL 规模披露审计	14
4.1 直接公开的数字	14
4.2 训练数据比例：能答到什么程度	15
核心审计结论	15
4.3 容易被误写进报告的数字	15
第五部分 可执行 Roadmap (12–16 周参考架构)	16
5.1 总路线	16
5.2 Phase 0：先建测量系统，不先训模型 (W0–2)	16
5.3 Phase 1：SFT 只负责“会说、会调用、会恢复” (W2–4)	16
5.4 Phase 2：按领域训练 specialist RL (W4–9)	17
5.5 Phase 3：长程 rollout 系统 (W5–10，与 RL 并行)	17
5.6 Phase 4：Multi-teacher OPD (W10–13)	18
5.7 Phase 5：发布门禁、QAT 与反作弊 (W13–16)	18
5.8 一个可落地的后训练算力 prior	18
5.9 每周 Dashboard	19
5.10 架构决策表	19
第六部分 教学计划：4 周、8 节、每节 90 分钟	20
6.1 学习目标	20
6.2 课前阅读顺序	20
6.3 Session 1 建立后训练地图	20
6.4 Session 2 GLM-5 串行 pipeline 与 cross-stage OPD	20
6.5 Session 3 GLM-5.2：SAO 与 CompactionRL	21
6.6 Session 4 Kimi K3：9 experts 与 effort curriculum	21
6.7 Session 5 Kimi K3：Partial rollout 与环境工厂	21

6.8 Session 6 DeepSeek V4 : Specialist、GRM 与 OPD	22
6.9 Session 7 OPD 算法诊所	22
6.10 Session 8 Capstone : 设计自己的 16 周 pipeline	22
第七部分 Walk Me Through : 把三份报告串成一个系统	24
7.1 从一条 coding-agent trajectory 开始	24
7.2 你应该记住的五句话	24
第八部分 术语表	25
第九部分 风险、未知与研究问题	26
9.1 三家共同未知	26
9.2 可直接立项的研究问题	26
第十部分 官方来源与页码导航	27
GLM	27
Kimi	27
DeepSeek	27
最终结论	27

Executive Summary

先给结论

- 1 三家没有一条共同的“标准后训练 recipe”。GLM-5 的公开主线是串行塑形；Kimi K3 是 3 个领域 × 3 档 effort 的 9 专家分叉；DeepSeek V4 是按领域和 reasoning effort 训练 specialist，再用超过 10 个 teacher 合并。
- 2 共同的战略结构是“先分化，再合并”。SFT 提供格式与冷启动，RL 把单项能力推高，On-Policy Distillation (OPD) 负责把专家能力重新压回一个统一 student，旨在降低顺序 RL 的遗忘和多能力混训的梯度干扰。
- 3 长程 Agentic RL 的真正瓶颈不只是算法，而是状态和算账。GLM-5.2 用 single-rollout critic PPO、learned compaction、token-level accounting；Kimi K3 用 partial rollout、持久 sandbox 和外部 KV pool；DeepSeek V4 用 token-level WAL、可抢占恢复和大规模 DSec。
- 4 “reasoning effort”是被训练出来的 policy family，不等于推理时改 max_tokens。Kimi 明确从 max 向 high/low 退火预算；DeepSeek 按不同 context 与 length penalty 训练 Non-think/High/Max；GLM-5.2提供 effort control，但没有公开完整配方。
- 5 最想知道的“后训练到底用了多少数据”，三家都没有完整公开。没有一家给出可复现的 SFT/RL/OPD 总样本、总 rollout、总生成 token、总步数、总 GPU-hours 和完整 domain mix。报告中最显眼的环境数、网页数、sandbox 数、并发数都不能替代 RL 数据量。
- 6 如果要落地，优先复制它们的结构原则，而不是猜一个神秘比例。推荐先完成数据账本、可验证环境、trajectory schema 和回归矩阵；中等资源团队先做 3-4 个专家，小团队采用 GLM 式串行 checkpoint + cross-stage OPD，frontier 规模再扩到 9 或 10+ experts。

一页比较

维度	GLM-5 / GLM-5.2	Kimi K3	DeepSeek V4
完整报告状态	GLM-5 有完整报告；5.2 只有官方增量博客 + 方法论文	47 页 K3 technical report	58 页 V4 Preview technical report
主拓扑	GLM-5：SFT → Reasoning RL → Agentic RL → General RL → cross-stage OPD；5.2 增加并行 OPD	SFT → 3 域 × 3 effort = 9 RL experts → 专家轨迹 SFT consolidation + MOPD	Domain SFT → specialist GRPO → >10 teachers → full-vocab OPD
长程 RL	5.2：single-rollout critic PPO/SAO + CompactionRL	partial rollout + pause/resume + staleness regularization	WAL + 可抢占恢复 + DSec；specialist 内仍用 GRPO
GRM / reward integrity	GLM-5 General RL 用 GRM/ORM；5.2 anti-hack judge 是 rollout guard，不是主观质量奖励	tournament-style Agentic GRM + rubric/scorepad	actor-as-GRM + rubric-guided RL；不使用传统 scalar RM
OPD 信号	GLM-5：sampled-token teacher/student log-ratio；5.2 只披露 >10 experts，loss 形式未知	clipped sampled-token dense reward；9 teachers	student on-policy 的加权 reverse KL；完整词表 logits；>10 teachers
公开后训练量	环境池、并发、group/batch、teacher 数；无总 RL 量	teacher 与 infra 数；无总 RL 量	teacher 数；无总 RL 量
最突出亮点	compaction 进入 policy；token-level credit；在线 anti-hack	effort curriculum；partial rollout；harness augmentation	full-vocab OPD；teacher 调度；WAL/provenance

第一部分 | 证据边界与阅读方法

1.1 三个 “report” 并不对称

- GLM-5.2：截至研究时点，没有题为《GLM-5.2 Technical/Training Report》的独立完整报告。官方模型卡并列引用 GLM-5.2 blog 与 GLM-5 technical report。因此本报告把 GLM-5 的完整 pipeline 与 5.2 的增量披露分开，不假定旧 recipe 全部原样继承。
- Kimi K3：有正式 47 页 technical report 和公开权重，但没有开放训练代码、训练数据集或足以完整复现的规模超参。
- DeepSeek V4：有正式 58 页 V4 Preview technical report；截至 2026-08-03 仍为 Preview，报告未披露完整后训练数据量。

1.2 什么才叫 “RL 做了多少数据”

对 agentic RL，单一 “样本数” 会严重误导。至少要同时报告：

```
RL 规模向量 = {  
  unique prompt/task seeds,  
  environments / repository states,  
  attempts per seed,  
  completed / accepted trajectories,  
  generated policy tokens,  
  observation tokens,  
  tool calls / interaction steps,  
  sandbox-hours,  
  optimizer steps / effective batches,  
  GPU-hours / FLOPs  
}
```

因此：

- 环境数 $\neq$ rollout 数；
- 来源网页数 $\neq$ RL prompt 数；
- sandbox 创建数 $\neq$ accepted episode 数；
- concurrent sandboxes $\neq$ 总训练数据量；
- 预训练 tokens $\neq$ 后训练 tokens；
- OPD 用时天数 $\neq$ OPD 样本数或计算量。

1.3 证据等级

标记	含义	示例
[D]	官方材料直接披露	Kimi 为 9 experts；GLM-5.2 OPD 合并 >10 experts
[C]	只做透明算术，不添加隐含假设	GLM 32K/128K/200K mid-training 合计 1.55T，占 28.5T 的约 5.44%
[R]	本报告依据三家共性给出的工程建议	试点期按生成 token 而非 prompt 数做 domain budget

第二部分 | 三条后训练 Pipeline

2.1 GLM：从串行塑形到长程 single-rollout RL

2.1.1 GLM-5 报告中的完整基础流水线 [D]

Serial path:
Overall SFT — Reasoning RL — Agentic RL — General RL

Explicit teacher taps in Figure 5:
Overall SFT ↘
Reasoning RL |—— Cross-Stage OPD — Unified final model
General RL ↘
Agentic RL as a direct teacher: not disclosed

来源：GLM-5 Figure 5 (p.4) 与 §3 (pp.10–14)。

Node	目标与做法	训练信号	已披露数量	未披露
Overall SFT	General Chat、Reasoning、Coding & Agent；支持 interleaved/preserved/turn-level thinking；错误 execution segment 保留在上下文但 mask loss	token CE；环境验证、rejection sampling、loss masking	最大 SFT 长度 202,752 tokens	三类比例、样本、tokens、epochs；5.2 是否同配方
Reasoning RL	数学、科学、代码、TIR 混训；GRPO + IcePop，处理训练/推理不匹配；无 KL	source-specific judge / evaluation system 的 binary outcome	四域 roughly balanced；group 32、batch 32；clip low 0.2/high 0.28	prompts、rollouts、steps、真实比例
Agentic RL	编码与搜索；trainer/rollout 完全异步；TITO、Direct Double-sided IS、DP-aware routing	可执行环境、测试和任务成功	>10K SWE env；数千 repos；9 语言；>1K concurrent rollout	总 episode、rollout、token、GPU-hours
General RL	foundational correctness、情商、task-specific quality	rules + ORM + GRM；human-authored quality/style anchors	无数数据量	reward mix、样本量、人类偏好量
Cross-stage OPD	Figure 5 明确以 Overall SFT、Reasoning RL、General RL checkpoints 作 teachers；未明确 Agentic RL 是否直接作 teacher	sampled-token teacher/student logit gap，作为 dense token signal	group 1、batch 1024；teacher prompt 来自前序 RL sets，比例仅称 appropriate	teacher mix、prompts、tokens、steps

2.1.2 GLM-5.2 的增量 [D]

GLM-5 family foundation

- substantially expanded 1M coding-agent training
- long trajectories → trainable compaction sub-traces
- group-wise RL → single-rollout critic PPO / SAO
- online anti-hack: rule recall → LLM intent judge → block tool call
- parallel OPD: merge >10 experts in ~2 days

增量一：1M coding-agent training。官方只说 substantially expanded，覆盖大型实现、自动研究、性能优化和复杂 debugging；没有给样本、token、step 或 SFT/RL 占比。

增量二：Single-Rollout Asynchronous Optimization (SAO)。5.2 官方博客明确：长轨迹的 group sampling 会产生 straggler 和 policy lag，因此转向 critic-based PPO，每 prompt 可只采一条 rollout，由 critic 给 token-level advantage。SAO 方法论文还提出 rollout-policy importance ratio、strict double-sided token clipping、冻结 critic attention 与 skip-observation GAE；论文实验中的 critic:actor 2:1 更新比不能当作 5.2 production 超参。

增量三：CompactionRL。summary 不再是 inference heuristic，而是同一 trainable policy 的动作。summary tokens 与 execution tokens 共享最终 task reward；token-level loss normalization 避免“压缩次数更多的 trajectory 权重更大”；cross-trajectory GAE 负责跨 compaction segment 分配 credit。方法论文实验默认保留最近 k=2 个 interaction steps，5.2 production 的实际 k 未披露。

增量四：Online anti-hack。规则过滤器先追求高 recall，LLM judge 再识别意图；被判定为作弊的 tool call 被阻断并返回 dummy result，但整条 rollout 继续。这保留了未作弊片段的训练价值。


增量五：Parallel OPD。slime 支持 white-box/black-box rollout、compact trajectory 与 sub-agent workflow；5.2 在约两天内合并超过 10 个 expert，但没有公开 teacher 清单、配比、GPU 或 OPD token 量。

2.1.3 GLM 的核心设计逻辑

- 短、可验证推理可以依靠 group-relative advantage；长、异长、会 compaction 的 agent 轨迹需要 critic 解决 group size 1 和跨 segment credit。
- TITO、token-level loss、skip-observation GAE 和 cross-trajectory GAE 都指向同一个问题：长程 RL 首先是一套 token accounting system。
- GLM-5 的 cross-stage OPD 同时承担能力合并与 anti-forgetting；5.2 的 >10 experts 只能证明最终阶段存在并行专家汇合，expert 来源及其是否由前序串行 checkpoints 演化而来未披露。

2.2 Kimi K3：3 域 × 3 effort 的 9 专家系统

2.2.1 总流水线 [D]



QAT 从 SFT 开始贯穿 RL；routed MoE experts 在 trainer 与 rollout 中使用对齐的量化方案。主模型之外，MTP 层被微调为 EAGLE-3-style draft model。

2.2.2 节点拆解 [D]

Node	方法	已披露数量	未披露
SFT	前代 Kimi domain models 合成长智能体轨迹；multi-stage verification + HITL；XTML 分隔 think/response/tool	只称 large-scale	样本、tokens、域比例
领域分叉	general tasks、general agents、coding agents	3 domains	每域数据量与采样率
Effort curriculum	从 cold-start 估计每题 $b_0(x)$ ；超过 $\tau \cdot b_0(x)$ 的 trajectory reward=-1；先 max，再 anneal τ 得 high/low	3 efforts；合计 9 experts	τ 、hard cap、各档 token 分布
Partial rollout	N prompts $\times$ K completions；全局完成 λNK 后暂停剩余生成；只有某 prompt 的 K 条 response 全部完成，该组才进入 optimization；其余跨 iteration 恢复	N 、 K 、 λ 仅为符号	实际 batch、iteration、rollout 数
Agentic GRM	tournament-style binary comparison；judge 读产物、生成 rubric、逐项打分并写 scorepad；verbosity 过高会输	无	judge 型号、样本、reward mix
Supervised consolidation	收集 9 专家生成的轨迹，用于 unified student 的 supervised fine-tuning，再进入 MOPD	来源为 9 experts	轨迹、token 与领域比例
MOPD	按 domain+effort 选 teacher；student 自采样；clipped teacher/student log-prob ratio 形成 dense token reward	9 teachers	R_{max} 、prompt mix、steps、tokens
QAT	routed MoE expert weights 用 MXFP4，其输入 activations 用 MXFP8；attention/latent-MoE projections、shared experts、routers 保持更高精度	从 SFT 开始	额外成本和数据量
Draft model	冻结 target，训练 MTP/draft layer 与 fusion；LK acceptance-rate loss	7-step unroll	数据量

2.2.3 为什么 partial rollout 很关键

传统同步 group rollout 必须等最慢的 trajectory。K3 在全局达到 λNK 条 completion 后暂停剩余 generation；只把已经凑齐 K 条 response 的 prompt groups 送入 policy optimization，其余 rollout 保存后跨 iteration 恢复。代价是恢复 trajectory 来自较旧 policy，因而需要 per-token off-policy regularization 限制 staleness。

报告引用 Kimi K2.5 的 policy optimization，而不是重新给出 K3 完整超参。因此 K2.5 公式可以帮助理解机制，但不能把 K2.5 的数值配置写成 K3 的训练规模。

2.2.4 Kimi 的训练对象已经是“环境包”


training item = initial state

- + tool / system prompt / memory / skill / subagent harness
- + execution budget
- + evolving environment state
- + public / hidden verifier
- + terminal outcome

Unified White-Box RL Environment 可组合工具、system prompt、context management、skills、memories 与 subagents，并实例化 Kimi Code、Claude Code、Codex、OpenClaw、Hermes 风格 harness。Harness 变化本身就是 data augmentation，防止模型只适应固定框架。

2.3 DeepSeek V4 : Specialist GRPO 与完整词表 OPD

2.3.1 总流水线 [D]



一个必须澄清的误解：V4 没有取消 RL。它仍在每个 specialist 内做 SFT + GRPO；被 OPD 替换的是 V3.2 最终用于能力合并的 mixed RL。

2.3.2 节点拆解 [D]

Node	方法	已披露数量	未披露
Domain SFT	数学、代码、agent、instruction following 等领域独立 SFT	无	样本、tokens、domain mix
Specialist RL	GRPO；训练设置只称与 R1/V3.2 接近	无	group、batch、steps、rollout、tokens
Effort specialists	RL 中使用不同 context window 与 length penalty	Non-think / High / Max	训练 context、penalty、token budget
Verifiable reward	simple rule verifier / test cases	无	题量与 rollout
Hard-to-verify reward	rubric-guided RL data + Generative Reward Model；不用传统 scalar RM；actor 本身兼任 GRM，GRM 也被 RL 优化	人工标注只称 minimal	标注数、rubric 粒度、GRM mix、独立校准
Multi-teacher OPD	student 自采样 trajectory；加权 reverse KL；完整词表 logits	>10 teachers	teacher 清单、w_i、trajectory、token、step、算力
QAT	MoE expert weights 与 CSA indexer QK path 用 MXFP4；rollout 原生 FP4	top-k selector 2x，KV recall 99.7%	QAT 数据与后训练成本
Agent infra	DSec、全序 trajectory log、token-level WAL、可抢占恢复	单集群几十万 concurrent sandboxes	总 episode 与 RL 数据量

2.3.3 Full-vocabulary OPD 为什么不同

DeepSeek 的概念目标为：

$$L_{\text{OPD}}(\theta) = \sum_i w_i \cdot \text{KL}(\pi_{\text{student}}(\cdot | s) || \pi_{\text{teacher}_i}(\cdot | s))$$

trajectory 来自 student 本身；在每个 token 位置比较整个词表分布，而不是只比较实际采样 token。优点是更低方差、更完整地保留 teacher 的“次优选项结构”；代价是词表超过 100K 时 teacher logits 成本巨大。

DeepSeek 的工程解法是把 teacher 权重放在集中存储，缓存最后一层 hidden state，需要时只运行对应 teacher LM head 重建 logits，并配合专用 kernel。报告没有给 full-vocab OPD 对 sampled-token OPD 或 mixed RL 的直接完整消融，因而“更稳定”仍需在自己的栈里验证。

2.3.4 WAL 解决的不只是可靠性

长 rollout 被抢占后若从头生成，短回复更容易完成并进入训练，造成隐性 length bias。token-level Write-Ahead Log 记录生成 token 并配合 KV cache 从精确位置恢复；独立的 DSec trajectory log 记录环境命令、结果、provenance 并支持 deterministic replay。两套日志共同服务统计正确性与可恢复性，而不只是运维优化。

第三部分 | 横向比较：相同目标，不同技术选择

3.1 Pipeline 拓扑

问题	GLM-5.2	Kimi K3	DeepSeek V4
能力如何分开训练	GLM-5 先串行 Reasoning/Agentic/General ; 5.2 另有 >10 experts，但来源未完整重述	明确 3 域 × 3 effort	按 domain + effort 建 specialist，>10 teachers
如何统一	cross-stage / parallel OPD	9-teacher MOPD	weighted full-vocab reverse-KL OPD
对遗忘的处理	前序 checkpoints 做 teacher	专家先独立，再统一蒸馏	specialist learning 与 capability merging 解耦
适合的组织形态	小中团队可串行；5.2 已向并行扩大	需要至少 9 个训练分支及环境工厂	需要 teacher scheduling 与 logits 基础设施

3.2 RL 算法选择

场景	最匹配的公开设计	原因
短、同质、可验证问题	GLM-5 GRPO / DeepSeek specialist GRPO	group-relative baseline 简单，无 critic；同 prompt 多样本可比较
超长、长度差异大、每 prompt 采样昂贵	GLM-5.2 single-rollout critic PPO / SAO	group size 1；critic 给 token-level advantage；减少等待和 policy lag
大量长尾 straggler，但希望保留 group-based 更新	Kimi partial rollout	完成阈值后先更新，未完成任务跨 iteration 恢复
强抢占、多租户、超长 agent	DeepSeek WAL + persistent sandbox	精确恢复，避免重复 rollout 与 length bias

这些选项并非互斥：可在同一平台上对短推理用 GRPO，对长 agent 用 single-rollout PPO；partial rollout 和 WAL 属于 rollout scheduler/state layer，可以同时存在。

3.3 Reward 设计

三家都形成了分层 reward stack：

Level 1 deterministic verifier / tests / final state
Level 2 hidden verifier + anti-hack checks
Level 3 rubric-guided GRM / LLM judge for subjective outcomes
Level 4 cost, verbosity, length or effort-budget constraints
Level 5 OPD dense token signal for consolidation

差异在于：

- GLM-5.2 把 anti-hack 放进 rollout 主循环，阻断作弊动作但继续 trajectory。
- Kimi 的 verifier 与具体环境紧密绑定：kernel 正确性/性能、AET final state、web build/pixel、personal-assistant events。
- DeepSeek 让 actor 兼任 GRM，减少独立 RM，但更容易出现 self-evaluation 的相关性错误；落地时应增加独立 judge 与人工校准。

3.4 OPD 的三种实现

维度	GLM	Kimi	DeepSeek
teacher 来源	GLM-5 : Overall SFT/Reasoning RL/General RL checkpoints ; 5.2 : >10 experts , 来源未披露	明确 3 domain × 3 effort	>10 teacher models covering various domains ; 具体 domain/effort 构成未披露
student 数据	on-policy	on-policy	on-policy
信号粒度	GLM-5 为 sampled-token log gap ; 5.2 parallel OPD 的 loss 未披露	clipped sampled-token log-ratio dense reward	full-vocabulary weighted reverse KL
主要优点	实现较轻 ; 适合 cross-stage retention	teacher routing 清晰 ; 与 RL reward 同框架	低方差、保留完整分布结构
主要成本/风险	只看采样 token , 信息较少	staleness、teacher routing、clip 设计	teacher hidden/logit 调度昂贵 ; w_i 未公开

3.5 长上下文的三种 “状态观”

- GLM : 把 memory/compaction 变成 policy action 。 固定阈值触发 compaction ; 模型学习摘要内容以及压缩后如何继续执行 , 最终任务奖励反传到 summary 。
- Kimi : 把未完成 trajectory 视为可暂停的作业 。 AgentENV sandbox 支持 pause/resume/fork/snapshot ; KV/KDA/MLA state 另行 retention、offload 与 prefetch 。
- DeepSeek : 把每个 token 与环境事件视为可重放日志 。 WAL 和全序 trajectory log 保证 provenance 与确定性恢复 。

它们可以组合成更完整的架构 : policy-level compaction + scheduler-level partial rollout + storage-level WAL 。

第四部分 | 数据比例与 RL 规模披露审计

4.1 直接公开的数字

模型	阶段	[D] 官方数字	正确解释
GLM-5	全基础训练	28.5T tokens	pre/mid-training 总预算背景，不是后训练量
GLM-5	long-context mid-training	32K: 1T ; 128K: 500B ; 200K: 50B	合计 1.55T ; 相对 28.5T 的 [C] 约 5.44% , 不是官方 data mix 百分比
GLM-5	issue-PR	约 10M pairs ; 160B unique tokens	数据源/unique token 规模 ; 有 upsampling , 不能直接除以总 token 得采样比例
GLM-5	Reasoning RL	math/science/code/TIR roughly balanced ; group 32 、 batch 32	“roughly” 只能说近似 1:1:1:1 , 不能写精确 25%
GLM-5	SWE environments	>10K env , 数千 repos , 9 languages	环境池 , 不是 rollout 总量
GLM-5	terminal/search	数千 terminal env ; >2M high-information pages	env/source count , 不是 RL samples
GLM-5	rollout infra	>1K concurrent rollouts	并发能力 , 不是总 rollouts
GLM-5	cross-stage OPD	group 1 、 batch 1024	optimizer configuration ; 无总 prompts/tokens
GLM-5.2	parallel OPD	>10 experts ; 约 2 days	teacher 数与墙钟时间 ; 无 GPU 、 tokens 、 steps
Kimi K3	RL experts	3 domains × 3 efforts = 9	teacher count , 不能推出每域比例
Kimi K3	single experiment	few hundred GPUs for co-located 1M-context RL	单实验资源量级 , 不是总 GPU-hours
Kimi K3	AgentENV	51,219,741 sandboxes / 1,505,678 images	training + evaluation 总创建规模 ; images 是 container filesystem images
Kimi K3	checkpoint/resume	最低 133ms / 49ms ; 最高 6.5× memory overcommit	infra latency/density , 不是训练量
Kimi K3	long trajectory	单条可达数千 tool calls 、数百万 cumulative context tokens	代表性上限 , 不是均值或总量
DeepSeek V4	pretraining	Flash 32T ; Pro 33T	预训练 tokens , 不是后训练
DeepSeek V4	token batch	Flash 75.5M ; Pro 94.4M	pretraining batch setting
DeepSeek V4	OPD	>10 teachers	无 teacher mix 、 trajectory 或 token 量
DeepSeek V4	DSec	单集群几十万 concurrent sandboxes	容量 , 不是 episode 总量

4.2 训练数据比例：能答到什么程度

问题	GLM-5.2	Kimi K3	DeepSeek V4
SFT 样本/token 总量	未披露	未披露	未披露
SFT domain 比例	三大类，无比例	无比例	无比例
RL prompt/episode/rollout 总量	未披露	未披露	未披露
RL generated tokens	未披露	未披露	未披露
RL 各域比例	GLM-5 Reasoning 四域 roughly balanced ；5.2 未披露	只有 3 域结构，无比例	只有 domain specialist 结构，无比例
RLVR vs GRM/RLAIF-like 比例	未披露	未披露	未披露
OPD 数据量与 teacher 权重	未披露	未披露	未披露
后训练 GPU-hours/FLOPs	未披露	RL scaling 图无绝对刻度	未披露

核心审计结论

不能从官方报告还原三家的真实 post-training data mixture，也不能严格比较谁“RL 做得更多”。最多可以比较 pipeline 的结构复杂度、环境/系统能力、teacher 数和少数局部训练配置。


4.3 容易被误写进报告的数字

- SAO 的 batch 128、group 1、max 128K、约 1,000 steps 与 critic:actor 2:1 更新比来自 Qwen3-30B-A3B 方法实验，不是 GLM-5.2 744B/750B 的 production config。
- CompactionRL 的 50-step critic pretrain、64K/80K context、最多 3 次 compaction 与最近 k=2 步保留设置来自 GLM-4.7-Flash / GLM-4.5-Air 方法实验，不是 GLM-5.2 实际规模。
- K3 第三方 Day-0 LoRA/DAPO 示例的 64 samples/rollout、60 steps、12 小时不是 Moonshot 原始 K3 training recipe。
- DeepSeek-V3.2 的 >1,800 environments、85K prompts 和数千 RL steps 不能归给 V4。
- Kimi 的 51M sandbox、DeepSeek 的几十万并发 sandbox、GLM 的 >1K 并发 rollout 都属于 infrastructure 指标。

第五部分 | 可执行 Roadmap（12–16 周参考架构）

以下均为 [R] 本报告建议，不是三家公开的实际训练配方。假设已经有可用 base/cooldown model、一个中等规模训练团队，并希望做 reasoning + coding + agent 的统一模型。

5.1 总路线



5.2 Phase 0：先建测量系统，不先训模型（W0–2）

交付物

- 统一 trajectory schema：model messages、thinking visibility policy、tool call/result、environment state、reward components、termination reason。
- 数据账本：origin、license、domain、difficulty、harness version、teacher、verifier、model version、tokens、tool steps、sandbox time、reward、hack flag、compute。
- capability vector 与 retention matrix：reasoning、code、agent、general、safety、latency/cost。
- public verifier 与 hidden verifier 分离；构造 reward-hacking red-team set。

进入下一阶段的门槛

- 95%+ 轨迹可 deterministic replay；
- verifier 在人工审计集上的误判率可接受并有 confidence interval；
- 每个样本都能追溯数据、环境、模型与 reward 版本；
- 评估集与训练源严格去重。

5.3 Phase 1：SFT 只负责“会说、会调用、会恢复”（W2–4）

建议起始 domain mix（按有效训练 token 计）

Domain	[R] 初始比例	目的
reasoning / science / TIR	25%	稳定思考、计算与工具推理格式
coding / SWE / terminal	30%	executable task 与纠错轨迹
agent / search / knowledge work	30%	多步工具、状态管理、长任务
general / instruction / style / safety	15%	基础可用性、风格与边界

这是启动 prior，不是固定真理。每周按 holdout marginal gain、生成 token 成本和 regression 调整，而不是追求某家未公开的比例。

数据策略

- 优先 high-quality execution trajectories，而不是堆静态问答。
- 错误动作可保留为上下文，但 mask 对应 loss，让模型学习 recovery 而不 imitation error。
- Tool schema、harness、system prompt、memory 配置做受控随机化。
- QAT/serving precision 如已确定，应从 SFT 开始进入闭环。

门槛

- 格式、tool schema、argument typing、parallel tool call 成功率稳定；
- recovery task 明显优于 base；
- SFT 不再带来显著收益时停止，避免把 specialist 能力都寄托于 imitation。

5.4 Phase 2：按领域训练 specialist RL (W4–9)

分支建议

- 小团队：reasoning → coding/agent → general 的串行 checkpoint，每个阶段保留 teacher snapshot。
- 中等团队：reasoning、coding、agent/search 三个并行 specialist；先做 high/max effort。
- 大团队：再按 low/high/max 分叉，扩到 9 experts；只有在 teacher 增量互补性成立时再扩到 >10。

算法选择

- 短、可验证、可做同 prompt 多样本：GRPO，group 4–16 作为试点范围。
- 长、昂贵、异长：single-rollout critic PPO；critic 单独校准并监测 value drift。
- Subjective task：rubric-guided GRM，但 judge 与 actor 解耦，至少加入一个独立模型和 5–10% 人工抽检。

预算口径

不要只按 prompt 数配比；至少以 $\text{generated policy tokens} \times \text{environment cost factor}$ 做等价负载，并同时报告 tool steps、sandbox-hours 和成功率。

门槛

- 每个 specialist 在独立 holdout 上有显著提升；
- 计算边际收益 ($\Delta \text{quality} / \text{GPU-hour}$) 未进入平台期；
- hidden verifier 与 public verifier gap 不扩大；
- hack rate、verbosity、tool failure 和 cost 均有 guardrail。

5.5 Phase 3：长程 rollout 系统 (W5–10，与 RL 并行)

最小组合

- 1 persistent sandbox + exact environment version；
- 2 token/tool-event WAL 与 deterministic replay；
- 3 pause/resume/fork + KV retention/offload；
- 4 partial rollout scheduler，记录 policy lag；

- 5 compaction policy 与最近交互保留策略；
- 6 token-level loss normalization 与 observation mask；
- 7 online anti-hack guard，阻断动作但尽量保留 trajectory。

选择建议

- 轨迹主要受 context window 限制：优先 learned compaction。
- 轨迹主要受 straggler/环境等待限制：优先 partial rollout。
- 集群抢占或多租户明显：优先 WAL。
- 三者同时存在：组合使用，分别作用于 policy、scheduler、storage 三层。

5.6 Phase 4 : Multi-teacher OPD (W10–13)

推荐实验顺序

- 1 先做 3–4 teachers，保留一个 mixed-RL 或 trajectory-SFT baseline；
- 2 对比 sampled-token OPD 与 full-vocab OPD 的 capability retention / cost；
- 3 建 teacher routing 与权重表，按 domain × effort 显式记录；
- 4 student 必须自己 rollout，避免只吃 teacher 离线静态数据；
- 5 只有当新增 teacher 在 retention matrix 上提供互补能力时扩到 9 或 >10。

门槛

- 各 specialist 的主要能力保留率达到预设阈值；
- general/safety 不因合并明显回退；
- OPD 收益相对 GPU-hour 和 serving cost 合理；
- teacher routing 失败案例经过抽样分析。

5.7 Phase 5 : 发布门禁、QAT 与反作弊 (W13–16)

- rollout/trainer/serving precision、kernel、sampling mask、tool template 对齐；
- reward-hack suite、hidden verifier、cross-harness evaluation；
- low/high/max 分别评估质量、延迟、token、tool steps、环境失败；
- 线上灰度记录 preserved reasoning/history 缺失、compaction failure、过度主动、无效 debugging；
- 回滚点保留 SFT、每个 specialist、OPD 前后 checkpoints。

5.8 一个可落地的后训练算力 prior

工作包	[R] 起始占比	调整依据
SFT cold start	12%	格式/工具/恢复是否已饱和
specialist RL	50%	每域 Δ quality / GPU-hour
multi-teacher OPD	23%	retention 增益与 full-vocab 成本
hardening、QAT、ablation、red-team	15%	hack/回归/部署差异风险

这个 12/50/23/15 只是项目管理初值。实际应设置周度再分配，而不是把一次比例写死。

5.9 每周 Dashboard

类别	必看指标
Data	unique seeds、domain/difficulty mix、accepted/rejected、dedup、source coverage
Rollout	generated/observation tokens、tool steps、completion rate、pause/resume、policy lag、sandbox-hours
Learning	reward、value calibration、clip fraction、KL/OPD loss、gradient/entropy、 Δ quality/GPU-hour
Reward integrity	public-hidden gap、judge disagreement、hack rate、false positive、reward/real-success correlation
Capability	domain score vector、retention matrix、cross-harness generalization、low/high/max Pareto front
Serving	latency、cost、KV、compaction frequency、tool error、QAT parity

5.10 架构决策表

如果你的约束是…	推荐起点	不要急着做…
资源较小、团队 <20 人	GLM 式串行 specialist snapshots + cross-stage token OPD	一开始训练 9–10+ experts
中等资源、3 个核心能力域	3–4 并行 specialists + Kimi 式 teacher routing	没有 retention matrix 就做大规模 MOPD
长 agent rollout 极昂贵	group 1 critic PPO + partial rollout + WAL	强制每 prompt 等 K 条完整轨迹
有 full-logit/teacher infra	DeepSeek 式 full-vocab OPD 小规模 A/B	默认认为它一定优于 sampled-token
Reward hacking 高	hidden verifier + online action blocking + independent judge	只在训练后离线删 trajectory
serving 要 FP4	从 SFT 开始做 train/rollout/serve parity	最后一步才量化

第六部分 | 教学计划：4 周、8 节、每节 90 分钟

6.1 学习目标

完成后，学习者应能：

- 1 从一份 technical report 重建后训练 DAG，而不把 benchmark 或 infrastructure 数字当训练量；
- 2 解释 SFT、GRPO、PPO/critic、RLVR、GRM、OPD 的角色边界；
- 3 为短推理与长 agent 分别选择 rollout/optimization 方案；
- 4 比较 sampled-token 与 full-vocabulary OPD；
- 5 设计 domain × effort 专家与合并实验；
- 6 写出含数据账本、验证器、算力与发布门槛的 roadmap。

6.2 课前阅读顺序

- 1 GLM-5：Figure 5 p.4；§3 pp.10–14；§4 pp.15–20。
- 2 GLM-5.2 官方博客：1M context、slime、long-horizon RL、anti-hack。
- 3 SAO §3 与 CompactionRL §4；只理解机制，不把方法实验超参当 5.2 production 配置。
- 4 Kimi K3：§4.1–4.2 pp.12–17；§5.3 pp.21–22。
- 5 DeepSeek V4：§4 pp.24–26；§5.1–5.2 pp.28–36。

6.3 Session 1 | 建立后训练地图

讲授（35 分钟）

- Base/mid-training/SFT/RL/OPD 各解决什么问题；
- 数据、环境、rollout、optimizer step、算力五种“规模”口径；
- 为什么 agentic task 的样本是 environment package。

练习（35 分钟）

把三份报告的所有数字贴到五列：data source、environment、rollout、optimization、infrastructure。凡不能确定的写“未知”。

验收（20 分钟）

能解释为什么 51M Kimi sandboxes、>1K GLM concurrent rollouts、DeepSeek 几十万 concurrent sandboxes 都不能回答“RL 做了多少条数据”。

6.4 Session 2 | GLM-5 串行 pipeline 与 cross-stage OPD

讲授

- Overall SFT → Reasoning RL → Agentic RL → General RL；
- group-relative advantage 的直觉；
- 顺序 RL 为什么造成能力回退，checkpoint teacher 如何修复。

白板练习

同一 prompt 的 4 个 reward 为 $[0, 0, 1, 1]$ 。计算组均值并判断哪些 token 更新方向为正/负；讨论 group 全为 0 时发生什么。

验收问题

为什么 group size 1 的 GRPO 不成立，而 OPD 可以 group size 1？

6.5 Session 3 | GLM-5.2 : SAO 与 CompactionRL

讲授

- async rollout 的 straggler 与 policy lag；
- critic、GAE、importance ratio、double-sided clipping；
- observation token 为什么不应像 action token 一样传播 advantage；
- summary 如何成为有 reward 的 policy action。

Walk-through

教学例子（沿用方法论文实验的 $k=2$ ，并非 5.2 production 参数）：假设任务需要 120K token，而训练窗口 64K；在第 45K token 生成 summary，保留最近 2 个交互，继续执行；最终测试通过。沿 execution → summary → 未来 action 画出 credit path，并解释为何要 token-level normalization。

验收问题

CompactionRL 与“运行时让另一个模型做摘要”有何本质区别？

6.6 Session 4 | Kimi K3 : 9 experts 与 effort curriculum

讲授

- 3 domains × 3 efforts；
- $b_0(x)$ 、 $\tau \cdot b_0(x)$ 、超预算 reward=-1；
- general task 与 agentic task 的 token 计量口径；
- low/high/max 为什么不是 max_tokens 三档。

练习

给 reasoning、coding agent、personal assistant 三类题分别设计 b_0 与 cost metric，说明哪些 token/tool call 应计入预算。

验收问题

为什么先训 max，再 anneal 得到 high/low，通常比直接截断 max policy 更合理？

6.7 Session 5 | Kimi K3 : Partial rollout 与环境工厂

Walk-through

教学例子（非 K3 真实超参）： $N=4, K=2, \lambda=0.5$ ，共 8 条 active rollout。假设最先完成的 4 条恰好组成 2 个完整的 K-response prompt groups，则这 2 组先更新；其余 rollout 保存 sandbox 与 KV-related state，在下一 iteration 恢复。若 4 条分散在 4 个 prompt，则没有完整 group 可直接送入 optimization。画出恢复 rollout 的 behavior policy 与 current policy 差异，解释 staleness regularization。

环境练习

为一个 web-development task 写出 initial state、tools、public verifier、hidden verifier、anti-hack、terminal state 和 harness variants。

验收问题

为什么 harness diversification 是 data augmentation？为什么 fork、重复生命周期以及 training+evaluation 混合，会使 sandbox count 与 episode count 不存在公开的一一映射？

6.8 Session 6 | DeepSeek V4 : Specialist、GRM 与 OPD

讲授

- “最终 mixed RL 被 OPD 替换” 不等于 “没有 RL” ；
- easy-to-verify 与 rubric-guided hard-to-verify ；
- actor-as-GRM 的效率与相关性错误 ；
- reverse KL 的 mode-seeking 直觉。

验收问题

为什么让 actor 自评可能放大系统性盲点？怎样用独立 judge、人工抽检和 hidden verifier 缓解？

6.9 Session 7 | OPD 算法诊所

Toy example

词表只有 A/B/C。Math teacher 分布为 $[0.8, 0.1, 0.1]$ ，Code teacher 为 $[0.1, 0.8, 0.1]$ 。若 student 只采样到 A，sampled-token reward 只看到 A；full-vocab KL 同时看到 B/C 的概率结构。讨论：

- teacher routing 错误会怎样；
- 两个 teacher 权重都为 0.5 是否一定合理；
- full-vocab 信息更多为什么也更贵；
- 如何用 retention matrix 评估能力是否合并成功。

作业

设计 3-teacher A/B：trajectory SFT、sampled-token OPD、full-vocab OPD 三组；写清主指标、成本、停止规则。

6.10 Session 8 | Capstone : 设计自己的 16 周 pipeline

输入

一个已有 base model、有限 GPU、目标为 code + research agent + general assistant 的团队。

必须交付

- 一张 pipeline DAG ；
- 4 个 node 的输入、输出、数据、reward、算法与 gate ；
- 一张 data ledger schema ；
- 一个 domain/effort budget ；
- 一张 retention matrix ；
- 一个 reward-hack test plan ；

- sampled-token vs full-vocab OPD 决策；
- 12-16 周里程碑和回滚点。

评分标准

维度	权重
证据与假设分离	20%
节点输入输出清晰	20%
reward/verifier 可审计	20%
rollout 与 compute 口径完整	15%
OPD/retention 实验有效	15%
发布门禁与风险控制	10%

第七部分 | Walk Me Through：把三份报告串成一个系统

7.1 从一条 coding-agent trajectory 开始

Step 1 | SFT 冷启动。模型先学会结构化输出、工具参数、观察环境、失败恢复。GLM 的 loss masking 告诉我们：错误动作可以留作上下文，但不要把它当正确 target；Kimi 的 XTML 说明 trajectory schema 本身是 alignment infrastructure。

Step 2 | 选择 RL 节点。短测试题可对同一 prompt 采多条并做 GRPO；长 SWE/agent task 若每条耗时不同，group 等待会浪费资源，转向 Kimi partial rollout 或 GLM single-rollout critic PPO。

Step 3 | 奖励分层。编译、单测、最终环境状态优先；再加 hidden verifier 抓 reward hacking；审美或开放式产物才交给 rubric GRM。不要让单一 LLM judge 同时决定所有 reward。

Step 4 | 管理上下文。若超窗，GLM 路线让 policy 学 compaction；若主要问题是等待和抢占，Kimi pause/resume 与 DeepSeek WAL 保留精确状态。

Step 5 | 训练 effort。Max policy 先学会解决问题；逐步收紧 token/tool budget，形成 High/Low。评估应比较 quality-cost Pareto，而不是只看准确率。

Step 6 | 能力合并。Reasoning、code、agent experts 都很强后，不直接混在一次 RL 里互相干扰；让 unified student 自己 rollout，再接受对应 teacher 的 dense OPD 信号。

Step 7 | 发布前闭环。QAT 与最终 serving kernel 进入 rollout；WAL/provenance 使失败可重放；retention matrix 确认合并没有丢能力；anti-hack suite 确认 reward 没被投机。

7.2 你应该记住的五句话

- 1 SFT 教会模型“怎样参与训练”，RL 教会它“怎样赢”。
- 2 长程 RL 的单位不是一条回答，而是一段可恢复、可验证、可计费的环境交互。
- 3 Group-relative RL 适合廉价多样本；昂贵长轨迹需要 critic 或异步恢复。
- 4 OPD 的价值是把能力学习与能力合并解耦。
- 5 看不见的数字就是未知，不要用 infra 数字替它填空。

第八部分 | 术语表

术语	一句话解释
SFT	用监督 target 做 token-level imitation，主要负责格式、基本行为和冷启动
RLVR	用规则、测试或可执行环境提供可验证 reward 的强化学习范式
GRPO	同一 prompt 多条 completion 内做 group-relative advantage，通常不需要 critic
PPO / critic	critic 估计 value/advantage；适合 group size 1 和长程 credit，但系统更复杂
GAE	在 bias/variance 间折中地估计序列 advantage
Importance ratio	当前 policy 与 behavior/rollout policy 的概率比，用于修正 off-policy drift
GRM	生成式奖励模型，用 rubric、解释或比较生成评价，而非只输出 scalar
OPD	Student 在自己的 on-policy states 上向 teacher 分布蒸馏
Sampled-token OPD	只在实际采样 token 上计算 teacher/student signal，成本较低
Full-vocabulary OPD	每个位置比较全词表分布，信息更完整、成本更高
Reverse KL	$KL(student \parallel teacher)$ ，更强调 student 高概率区域与 teacher 对齐
Partial rollout	未等所有 trajectory 完成就更新，未完成项保存状态后跨 iteration 恢复
WAL	Write-Ahead Log；记录生成 token 并配合 KV cache 精确恢复；环境 provenance/replay 由独立 trajectory log 负责
CompactionRL	把上下文摘要/压缩作为可训练 policy action，用最终任务 reward 监督
QAT	Quantization-Aware Training；在训练中模拟最终低精度部署行为
Retention matrix	行为 teacher/能力域，列为统一 student checkpoints，用来量化能力合并与遗忘

第九部分 | 风险、未知与研究问题

9.1 三家共同未知

- SFT、RL、OPD 的完整样本、token、rollout、step、GPU-hour；
- 各 domain 与 reward 类型真实比例；
- safety alignment 是否作为独立节点、使用多少数据；
- OPD 相对 mixed RL、offline distillation、weight merging 的充分消融；
- actor-as-judge 与 teacher self-bias 的跨模型校准；
- long-context agent 在真实用户分布上的失败率和成本。

9.2 可直接立项的研究问题

- 1 对同一长轨迹任务，SAO、partial rollout GRPO 和 standard async PPO 的 quality/GPU-hour Pareto 如何？
 - 2 learned compaction、external memory 与 larger context 的最优切换点在哪里？
 - 3 sampled-token OPD 何时已足够，full-vocab OPD 的增益来自低方差还是 richer dark knowledge？
 - 4 teacher 数从 3→9→10+ 的增益是否饱和，routing error 怎样增长？
 - 5 actor-as-GRM 如何避免 shared blind spot；是否需要跨模型 judge ensemble？
 - 6 online anti-hack 的 false positive 如何影响探索和能力上限？
-

第十部分 | 官方来源与页码导航

GLM

- 1 [GLM-5: from Vibe Coding to Agentic Engineering](#) , arXiv:2602.15763 。重点 : Figure 5 p.4 ; §3 pp.10–14 ; §4 pp.15–20 。
- 2 [GLM-5.2: Built for Long-Horizon Tasks](#) , Z.ai 官方博客 , 2026-06-16 。重点 : 1M Context 、slime 、Long-Horizon RL 、Anti-Hack 。
- 3 [GLM-5.2 官方模型卡](#) 。
- 4 [Single-Rollout Asynchronous Optimization for Agentic Reinforcement Learning](#) , 重点 §3 。
- 5 [CompactionRL](#) , 重点 §4 。

Kimi

- 6 [Kimi K3: Open Frontier Intelligence](#) , 重点 §4.1–4.2 pp.12–17 ; §5.3 pp.21–22 。
- 7 [Kimi K3 官方仓库](#) 。
- 8 [Kimi K3 官方模型卡](#) 。

DeepSeek

- 9 [DeepSeek-V4: Towards Highly Efficient Million-Token Context Intelligence](#) , 重点 §4 pp.24–26 ; §5.1–5.2 pp.28–36 。
- 10 [DeepSeek-V4 Preview 官方发布页](#) 。
- 11 [DeepSeek-V4 官方模型集合](#) 。

最终结论

这三份报告最值得学的，不是某个无法还原的“神奇数据比例”，而是后训练架构的三次重构：

- 从单一混合 RL，转向 domain/effort specialists ；
- 从一次性完整 rollout，转向 可压缩、可暂停、可恢复、可重放的长程轨迹 ；
- 从最后一轮 mixed RL，转向 student-on-policy 的 multi-teacher capability merging 。

真正可复制的 roadmap 是：把数据账本与 verifier 建在前面，把能力学习和能力合并拆开，把部署精度与 rollout 对齐，并把“未知”保留为未知。